Анализ данных и искусственный интеллект

Лекция 1. Данные, задачи, жизненный цикл ML-проекта

Стародубцев Илья Сергеевич

УрФУ, ИРИТ-РТФ
ИММ УрО РАН

3 семестр

Что вы получите на выходе

Цель дисциплины

Научиться доводить задачу анализа данных от постановки до работающего решения и уметь объяснить, почему решение можно применять.

К концу семестра вы сможете:

- подготовить «сырые» данные к анализу и провести разведочный анализ;
- поставить задачу машинного обучения и выбрать адекватную метрику качества;
- обучить и сравнить модели классического ML и нейронные сети;
- объяснить решение модели заказчику, а не только показать точность;
- осознанно использовать ИИ-ассистенты в собственной разработке.

Как устроен курс

Объём: 108 часов (3 з.е.)

- Лекции — 17 ч (6 лекций)
- Лабораторные — 34 ч (10 работ)
- Самостоятельная работа — 57 ч

Как разнесено по семестру

- 1-й полусеместр — только лекции
- 2-й полусеместр — только лабораторные

Лабораторные построены не на учебных, а на индустриальных кейсах реальных компаний.

Лек.	Тема
1	Данные, задачи, жизненный цикл
2	Сбор, EDA, предобработка
3	Обучение с учителем
4	Дисбаланс, SHAP, кластеризация
5	Глубокое обучение
6	ИИ-инструменты и визуализация

План сегодняшней лекции

1. Данные и ИИ: что за чем стоит и как соотносятся понятия (15 мин)
2. Типы данных и типы задач анализа данных (15 мин)
3. Жизненный цикл проекта: CRISP-DM и где теряется время (20 мин)
4. Пять индустриальных кейсов, которые вы будете решать (15 мин)
5. Этика, ответственность и границы применимости (15 мин)
6. Итоги и задание к следующему занятию (10 мин)

Данные как побочный продукт

Ключевая мысль

Почти все данные, с которыми вы будете работать, собирались *не для вас* и *не для анализа*.

- Биллинг оператора связи создавался, чтобы выставлять счета, а не чтобы предсказывать отток.
- Журнал транзакций банка нужен для проведения платежей, а не для поиска мошенничества.
- Отчёты подразделений заполняются людьми и в том формате, который удобен людям.

Отсюда пропуски, дубликаты, несогласованные форматы и смещения — и отсюда же вся дальнейшая работа.

Как соотносятся понятия



ИИ — системы, решающие задачи, которые традиционно требовали человека. Включает и подходы без обучения (экспертные системы, поиск, планирование).

ML — подмножество ИИ: правила не программируются, а извлекаются из данных.

DL — подмножество ML: многослойные нейронные сети, признаки формируются самой моделью.

Data Science — не слой в этой матрёшке, а деятельность: статистика + программирование + предметная область.

Базовый словарь: таблица «объект–признак»

Абонент	Стаж, мес	Тариф	Трафик, ГБ	Обращений	Ушёл
A-1001	34	Безлимит	41,2	0	нет
A-1002	3	Базовый	2,1	4	да
A-1003	18	Базовый	12,7	1	нет

- **Объект** (пример, наблюдение) — строка
- **Признак** (фактор, feature) — столбец
- **Целевая переменная** — то, что предсказываем
- Признаки: числовые, категориальные, порядковые
- **Выборка** — набор объектов
- Модель: $\hat{y} = f(x_1, \ldots, x_n)$

Типы данных, с которыми вы столкнётесь

Тип	Пример	Особенность обработки
Табличные	выгрузки CRM, биллинг	классический ML работает лучше всего
Временные ряды	нагрузка на сеть по часам	порядок значим, нельзя перемешивать
Текст	обращения в поддержку	требуется векторизация
Изображения	фотоконтроль качества	свёрточные сети, много данных
Графы	связи абонентов, платежей	особые модели, отдельная область

На что обратить внимание

В этом курсе центр тяжести — табличные данные и изображения. Именно на них строятся все лабораторные работы.

Три режима обучения

С учителем

Есть размеченные примеры: известен правильный ответ.

Регрессия, классификация

Без учителя

Ответов нет, ищем структуру в данных.

Кластеризация, снижение размерности, аномалии

С подкреплением

Агент учится через взаимодействие и вознаграждение.

За рамками курса, упомянем обзорно

Практическое следствие

Разметка — самый дорогой ресурс. Именно её наличие или отсутствие чаще всего определяет, какой подход вообще возможен.

Регрессия и классификация

Регрессия

Предсказываем число.

- Какой объём продаж будет у подразделения в следующем квартале?
- Сколько минут продлится инцидент?

Ошибка измеряется отклонением: MAE, RMSE, R^2.

Классификация

Предсказываем метку из конечного набора.

- Уйдёт абонент в ближайшие 3 месяца или нет?
- Транзакция мошенническая или легитимная?
- Деталь годная или бракованная?

Качество: accuracy, precision, recall, ROC-AUC, PR-AUC.

Различие не в данных, а в постановке

«Выполнит ли подразделение план» — классификация. «На сколько процентов выполнит» — регрессия. Из одних и тех же данных получаются разные задачи.

Задачи без разметки

- **Кластеризация** — разбить объекты на группы по похожести. Сегментация абонентов, группировка обращений. Правильного ответа нет, оценка косвенная.
- **Снижение размерности** — сжать сотни признаков до нескольких при сохранении структуры. Нужно для визуализации и для ускорения моделей.
- **Детекция аномалий** — найти объекты, не похожие на основную массу. Отказы оборудования, нетипичное поведение в сети.

Типичная ловушка

Задачу поиска мошенничества почти всегда хочется решать как поиск аномалий. На практике, если разметка есть, классификация с учётом дисбаланса работает лучше. К этому вернёмся на лекции 4.

Проверим понимание: голосуем

Варианты ответа

А — регрессия **Б** — классификация **В** — кластеризация **Г** — аномалии

Называю номер — поднимаете руку на своём варианте.

1. Оценить, сколько заявок поступит в колл-центр завтра.
2. Разделить клиентов на группы для разных маркетинговых предложений.
3. Определить по фотографии, есть ли на детали трещина.
4. Найти датчики, показания которых ведут себя необычно.
5. Оценить вероятность того, что абонент расторгнет договор.

Проверим понимание: разбор

№	Ответ
1	А — регрессия
2	В — кластеризация
3	Б — классификация
4	Г — аномалии
5	Б — классификация

2: слово «разделить» без указания групп — разметки нет.

4: «необычно» — определения нормы не дали, её надо вывести из данных.

5: формально классификация, но нужна *вероятность*, а не метка. Удерживающее предложение стоит денег и отправляется не всем — абонентов нужно ранжировать по риску.

Вывод блока

Форма ответа определяет и метрику, и способ применения модели. Название типа задачи — вторично.

Проект — это не модель

Мысль, ради которой стоит запомнить эту лекцию

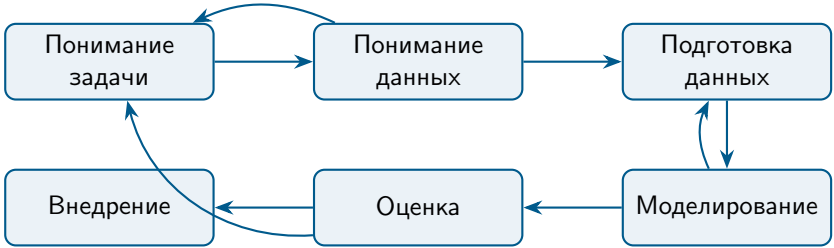
Обучение модели — это один из шести этапов, и обычно не самый долгий.

Что происходит вокруг модели:

- кто-то должен сформулировать, какое *решение* будет принято по результату;
- кто-то должен найти, выгрузить и согласовать данные;
- кто-то должен встроить модель в существующий процесс и следить за ней дальше.

Для описания этого цикла существуют стандартизованные методологии. Разберём две.

CRISP-DM: шесть фаз



- Цикл, а не конвейер: обратные стрелки — это норма, а не признак ошибки.
- Фаза оценки проверяет не только метрику модели, но и достижение исходной цели.

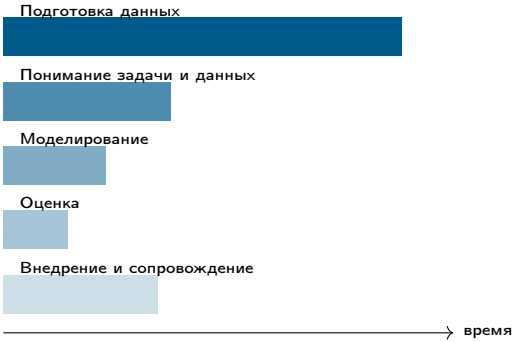
KDD и сравнение подходов

KDD (Knowledge Discovery in Databases)	**CRISP-DM**
Отбор данных	Понимание задачи
Предобработка	Понимание данных
Трансформация	Подготовка данных
Интеллектуальный анализ (Data Mining)	Моделирование
Интерпретация и оценка	Оценка
—	Внедрение

Существенное различие

KDD — академическая схема, она начинается с данных и заканчивается знанием. CRISP-DM — индустриальная: начинается с бизнес-задачи и заканчивается работающей системой. В производственных проектах опираются на CRISP-DM именно из-за первой и последней фаз.

Где на самом деле уходит время



Опросы практикующих специалистов из года в год дают одну и ту же картину: большая часть усилий приходится на поиск, очистку и согласование данных.

Следствие для вас: лабораторные работы 3–4 по предобработке — не разминка перед «настоящим» ML, а основная часть профессии.

Следствие для проекта: ускорять надо не обучение модели, а доступ к данным.

Две метрики, которые нельзя путать

Метрика модели

ROC-AUC, F1, RMSE.
Измеряет качество предсказаний. Понятна разработчику.

Метрика задачи

Сохранённые абоненты, предотвращённые потери, сокращение брака.
Измеряет пользу. Понятна заказчику.

Пример расхождения

Антифрод-модель с точностью 99,9 % бесполезна, если мошеннические транзакции составляют 0,1 % и модель просто всегда отвечает «легитимная». Формально она почти не ошибается; практическая ценность нулевая.

Связь между этими двумя метриками устанавливается на фазе понимания задачи, а не в конце проекта.

Почему ML-проекты не доходят до внедрения

- **Задача сформулирована не как решение.** Не ясно, что изменится в работе компании от предсказания.
- **Утечка данных в признаках.** В обучающую выборку попал признак, недоступный в момент реального применения. Модель показывает блестящий результат на тесте и проваливается в проде.
- **Несоответствие метрики цели.** Оптимизировали то, что удобно считать.
- **Данные изменились.** Поведение пользователей, оборудование, схемы мошенничества — всё дрейфует, модель устаревает.
- **Решение невозможно объяснить.** Регулятор или внутренний контроль не пропускают модель, которую нельзя обосновать.

Ни один из этих пунктов не решается выбором более сложного алгоритма.

Пять индустриальных кейсов

Раз.	Кейс	Задача	Лаб. работы
2	Ростелеком	Прогноз выполнения плана подразделениями	3–4
3	T2 (Tele2)	Прогноз оттока абонентов	5–7
3	Сбербанк	Детекция мошеннических транзакций	5–7
4	Дефектоскопия	Контроль качества по фотографии	9
5	ВЫЗОВ	Промт-инжиниринг и MVP-приложение	10

Зачем это устроено именно так

Каждая лабораторная — этап реального проекта, а не изолированное упражнение. Вы пройдёте весь цикл CRISP-DM, но на разных кейсах и с нарастающей сложностью.

Кейс 1: Ростелеком — разнородные источники

Что даётся

- Несколько выгрузок по подразделениям: план и факт продаж за периоды
- Несогласованные форматы дат и наименований
- Дубликаты, пропуски, аномальные значения

Что нужно сделать

- Свести источники в один датасет
- Обработать пропуски и выбросы
- Построить EDA-визуализации
- Сформулировать гипотезы о факторах риска невыполнения плана

Чему это учит

Реальные данные приходят не одним файлом и не в готовом виде. Умение свести их воедино и обосновать каждое принятое решение об очистке — базовый профессиональный навык.

Кейсы 2 и 3: Т2 и Сбербанк — классический ML

Т2: отток абонентов

- Бинарная классификация
- Классы несбалансированы умеренно
- Важна не метка, а вероятность: на кого тратить удерживающее предложение

Сбербанк: антифрод

- Бинарная классификация
- Сильный дисбаланс: мошенничество — доли процента
- Цена ошибок асимметрична: пропуск мошенника и блокировка честного клиента стоят по-разному
- Решение должно быть объяснимым

Здесь появится SHAP

Требование объяснимости — не формальность. Отказ клиенту нужно обосновать. Метод интерпретации моделей SHAP разберём на лекции 4; это единственный принципиально новый для программы блок.

Кейсы 4 и 5: изображения и ИИ-инструменты

Дефектоскопия (лаб. 9)

- Классификация изображений свёрточной сетью
- Данных мало: брак редок по определению
- Инструменты: аугментация, дообучение предобученной сети
- Цена пропуска брака высока

ВЫЗОВ (лаб. 10)

- Формат «вызова», а не пошаговой инструкции
- Промт-инжиниринг и работа с ИИ-ассистентами
- Результат — работающий MVP, а не блокнот с экспериментами
- Оценивается в том числе обоснование границ применимости

Последняя работа замыкает курс: вы применяете ИИ не только как предмет изучения, но и как инструмент собственной разработки.

Ответственный ИИ: пять принципов

- **Справедливость** — сопоставимое качество для разных групп людей
- **Прозрачность** — решение можно объяснить
- **Приватность** — данные защищены и обезличены
- **Надёжность** — предсказуемое поведение, в том числе на нетипичных входах
- **Подотчётность** — за решение отвечает человек, а не «модель»

Почему это на первой лекции, а не на последней

Все пять принципов реализуются на этапе подготовки данных и постановки задачи. Если про них вспомнить после обучения модели, исправлять придётся всё с начала.

Как предвзятость попадает в модель

- **Смещение выборки.** Данные собраны не со всей популяции. Модель оценки заявок, обученная только на одобренных кредитах, никогда не видела, как повели бы себя отклонённые.
- **Историческое смещение.** Данные корректно отражают реальность, но реальность содержала неравенство. Модель воспроизводит его и придаёт вид объективности.
- **Смещение разметки.** Разметку делали люди с собственными представлениями и усталостью.
- **Прокси-признаки.** Явно запрещённый признак удалён, но район проживания или модель устройства его косвенно восстанавливают.

Ни один из механизмов не обнаруживается по метрике качества. Их ищут целенаправленно, на этапе EDA.

Персональные данные

- Работа с персональными данными в России регулируется Федеральным законом № 152-ФЗ «О персональных данных».
- В учебных кейсах используются обезличенные или синтетические данные — это обязательное условие, а не упрощение.
- **Обезличивание — не удаление ФИО.** Комбинация нескольких «безобидных» признаков часто позволяет восстановить личность.
- Загрузка рабочих данных во внешние сервисы, включая ИИ-ассистенты, — типичный способ нарушить требования, не заметив этого.

Правило для лабораторных

Любые данные, полученные на этом курсе, остаются внутри учебного контура. Это же правило действует на производственной практике и в будущей работе.

ИИ-ассистенты в вашей собственной работе

Вы будете пользоваться генеративными моделями на протяжении всего курса — это прямо предусмотрено программой.

Три правила, которые действуют с сегодняшнего дня

1. **Ответственность за код несёт автор.** «Так предложила модель» — не объяснение на защите лабораторной.
2. **Всё, что предложено моделью, проверяется.** Особенно формулы, метрики и ссылки на библиотечные функции.
3. **Использование ассистента фиксируется.** В отчёте указывается, что и на каком этапе делалось с его помощью.

Эти правила не ограничивают вас, а переводят инструмент в разряд профессиональных.

Что нужно унести с этой лекции

1. ИИ $\supset$ ML $\supset$ DL; Data Science — деятельность на пересечении статистики, программирования и предметной области.
2. Тип задачи задаётся постановкой, а не данными: из одной таблицы получаются и регрессия, и классификация.
3. Проект живёт по циклу CRISP-DM; моделирование — лишь одна из шести фаз, и основное время уходит на данные.
4. Метрика модели и метрика задачи — разные вещи, и связывать их нужно в начале, а не в конце.
5. Этические требования реализуются в данных и постановке, а не добавляются в конце проекта.

Отметьтесь и ответьте



https://forms.yandex.ru/u/6aa7e74e6d2d732c04bbcc3d

Кодовое слово: _____

- Форма открыта до конца пары — это отметка о присутствии
- Пять вопросов из голосования — теперь письменно
- Последнее поле: что осталось непонятным

Последнее поле не оценивается. Оно нужно мне: с чего начнётся следующая лекция, зависит от ваших ответов.

Баллы за лекционную часть

Тест в elearn после каждой лекции

- Открывается сразу после лекции, закрывается через неделю
- 10 вопросов, две попытки, засчитывается лучшая
- Вопросы у каждого свои — выборка из банка
- Шесть тестов за полусеместр формируют лекционную часть БРС

Что важно понимать про сроки

Лабораторные начнутся только во втором полусеместре. Между этой лекцией и первой практикой пройдёт около двух месяцев. Тесты — единственное, что удержит материал в голове за это время.

Контрольные вопросы

1. Чем машинное обучение отличается от программирования правил вручную?
2. Приведите пример задачи, которую можно поставить и как регрессию, и как классификацию.
3. Назовите шесть фаз CRISP-DM и объясните назначение обратных переходов.
4. В чём принципиальное отличие CRISP-DM от KDD?
5. Почему высокая точность (accuracy) может свидетельствовать о непригодности модели?
6. Назовите два механизма появления предвзятости в данных и способ их обнаружения.

Литература и ресурсы

- Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение. — М.: ДМК Пресс.
- Мюллер А., Гвидо С. Введение в машинное обучение с помощью Python. — М.: Вильямс.
- Chapman P. et al. CRISP-DM 1.0: Step-by-step data mining guide. — SPSS Inc.
- Документация scikit-learn: `scikit-learn.org/stable/user_guide.html`
- Документация pandas: `pandas.pydata.org/docs`

Вопросы?